

学校代码: 10246

学 号: 22302010001

復旦大學

本 科 毕 业 论 文

基于小样本学习的机器人决策规划技术研究

Research on Robot Decision Planning Technology Based on
Few-Shot Learning

院 系: 计算与智能创新学院

专 业: 软件工程

姓 名: 任立德

指 导 教 师: 戈维峰 副教授

完 成 日 期: 2026 年 5 月 25 日

目 录

摘要	iii
Abstract	iv
第 1 章 引言	1
1.1 研究背景与意义	1
1.2 研究动机与核心问题	2
1.3 主要贡献	2
1.4 论文结构	3
第 2 章 相关工作	4
2.1 视觉语言模型	4
2.2 思维链推理	4
2.3 Code2Logic: 游戏逻辑驱动的数据合成	5
2.4 三维场景图构建	6
2.5 合成数据与域随机化	6
2.6 本章小结	7
第 3 章 方法	8
3.1 整体架构	8
3.2 Code2Logic: 方法论基础	8
3.3 Concept-Graphs: 真实场景标注管线	8
3.3.1 六步管线设计	8
3.3.2 结构化 Prompt 设计	9
3.3.3 GPU 推理加速方案	10
3.4 Isaac Sim: 合成真值验证	11
3.4.1 程序化场景生成	11
3.4.2 真值标注导出	11
3.5 跨源数据评估框架	11
第 4 章 实验	13
4.1 实验设置	13
4.1.1 硬件环境	13
4.1.2 软件环境	13

4.1.3	数据集	13
4.2	游戏数据合成实验	13
4.3	真实场景标注实验	14
4.3.1	跨场景标注结果	14
4.3.2	描述优化前后对比	15
4.3.3	识别率瓶颈分析	15
4.4	Prompt 消融实验	15
4.5	合成场景验证实验	16
4.6	推理模型选型实验	17
4.6.1	基准测试	17
4.6.2	实际管线对比验证	18
4.7	管线效率分析	18
4.8	三源数据对比	19
第 5 章	总结与展望	20
5.1	工作总结	20
5.2	研究局限性	21
5.3	未来工作展望	21
5.4	结论	22
	参考文献	23
	致谢	25

摘 要

三维场景理解任务面临高质量多模态标注数据稀缺的核心困境。人工标注成本高昂——单个室内场景（约 70 个物体）的完整标注可能需要数小时的专家劳动——导致标注数据的规模和多样性严重受限。现有自动生成方法虽然降低了成本，但在关系推理精度和跨场景泛化性上存在明显不足：视觉语言模型倾向于生成光照、氛围等场景级感官描述，而非精确的物体类别和空间关系信息。

针对上述问题，本文提出了一种融合游戏逻辑驱动合成、真实场景理解和仿真真值验证的三层数据自动标注方法。首先，将 Code2Logic 的模板化数据合成范式从二维游戏领域迁移至三维场景，以 Concept-Graphs 为框架整合 GradSLAM、Grounded-SAM、CF-SLAM、LLaVA v1.5 和 GPU 加速的大语言模型推理，构建了从 RGB-D 图像序列到结构化 QA 数据集的端到端六步自动处理管线。通过专门设计的结构化 prompt，将物体类别识别率从接近 0 提升至约 85%。其次，针对 Ollama 推理引擎存在的 CUDA 版本不兼容问题，通过 llama-cpp-python 源码编译方案将推理吞吐量从 3 tok/s 提升至 99 tok/s（33 倍提升），单场景 LLM 处理时间从 15 分钟降至 50 秒。最后，集成 NVIDIA Isaac Sim 仿真环境构建了合成真值验证系统，通过程序化场景生成和几何规则计算，实现了标注精度的可量化评估。

实验结果表明，本文方法在三类数据源（30 款 2D 游戏、7 个真实室内场景、20 个合成仿真场景）上累计产出 2395 条结构化 QA 数据，覆盖 Target Perception、Spatial Reasoning、Scene Comprehension、State Prediction 和 Strategy Optimization 共 5 种推理类型。跨源对比评估揭示了合成真值对推断标注的可量化校准能力——Isaac Sim 基于几何规则的空间关系准确率为 100%，而 Concept-Graphs 依赖模型推断的准确率约为 70%。5 款国内开源大语言模型的基准测试表明，Qwen2.5-3B 在速度和质量的平衡上为最优选择（86 tok/s，100% 格式合法率）。

本研究为三维场景的自动化标注提供了一套低成本、可扩展、精度可验证的完整解决方案，对视觉语言模型训练数据的构建和多模态场景理解系统的开发具有一定的理论价值和工程参考意义。

关键词：三维场景理解；数据合成；视觉问答；游戏逻辑驱动；仿真验证

中图分类号：TP391

Abstract

Three-dimensional scene understanding faces the fundamental challenge of scarce high-quality multimodal annotation data. Manual annotation is prohibitively expensive—a single indoor scene with approximately 70 objects can require hours of expert labor—severely limiting the scale and diversity of training data for vision-language models. Existing automatic methods reduce cost but exhibit significant shortcomings in relational reasoning accuracy and cross-scene generalization. Specifically, current VLMs tend to generate scene-level sensory descriptions (e.g., lighting conditions, atmospheric qualities) rather than precise object-level semantic information.

To address these challenges, this thesis proposes a three-tier data annotation framework that integrates game-logic-driven synthesis, real-world scene understanding, and simulation-based ground-truth verification. The framework begins by migrating the template-based data synthesis paradigm of Code2Logic from 2D games to 3D scenes. Using Concept-Graphs as the integration framework, we construct an end-to-end six-step pipeline that combines GradSLAM (3D reconstruction), Grounded-SAM (2D segmentation), CF-SLAM (object-level mapping), LLaVA v1.5 (multimodal description), and GPU-accelerated LLM inference (description refinement and relation reasoning). A specially designed structured prompt increases the object category recognition rate from near zero to approximately 85%. Furthermore, we identify and resolve a CUDA version incompatibility in the Ollama inference engine by source-compiling llama-cpp-python, achieving a 33× throughput improvement ($3 \rightarrow 99$ tok/s) and reducing per-scene LLM processing time from 15 minutes to 50 seconds. Finally, we integrate NVIDIA Isaac Sim to construct a synthetic ground-truth verification system, enabling quantifiable evaluation of annotation accuracy through procedural scene generation and geometric rule computation.

Experimental results demonstrate that our method produces 2,395 structured QA pairs across three data sources (30 2D games, 7 real indoor scenes, and 20 synthetic simulation scenes), covering 5 reasoning types: Target Perception, Spatial Reasoning, Scene Comprehension, State Prediction, and Strategy Optimization. Cross-source comparative evaluation reveals the quantifiable calibration capability of synthetic ground truth—Isaac Sim achieves 100% spatial relation accuracy via geometric rules, while Concept-Graphs LLM-inferred accuracy is approximately 70%. Benchmarking of five Chinese open-source LLMs identifies Qwen2.5-3B as the optimal choice (86 tok/s, 100% JSON validity).

This work provides a low-cost, scalable, and verifiable solution for automatic 3D scene annotation, offering both theoretical insights and practical engineering value for vision-language model training data construction and multimodal scene understanding system development.

Keywords: 3D scene understanding; data synthesis; visual question answering; game-logic-driven; simulation verification

CLC code: TP391

第 1 章 引言

1.1 研究背景与意义

三维场景理解是计算机视觉、机器人导航和人机交互领域的核心问题。与二维图像理解不同，三维场景理解涉及对物体类别、空间位置、几何形态和物体间语义关系的综合分析，其复杂度和信息维度远高于平面图像任务。随着视觉语言模型的快速发展，模型对二维图像的理解能力已达到前所未有的水平——LLaVA、Qwen2.5-VL 等模型能够以对话形式回答关于图像内容的复杂问题，在多个视觉问答基准上超越了人类水平。然而，当任务从二维平面拓展到三维空间时，模型面临着更为严峻的挑战。

Song 等人在 LLM-Planner 中的研究表明^[1]，在 Stanford VLN-CE 长程导航测试中，当任务步骤超过 5 步时，VLM 的决策准确率下降 37.2%。环境扰动——如物体位移、光照变化、动态障碍——使 VLM 的动作成功率进一步降低 42.8%。这些数据揭示了两大核心瓶颈：一是多步推理中空间语义连贯性的断裂，二是模型对环境变化缺乏鲁棒的适应性。

上述瓶颈的深层根源之一是高质量多模态场景理解数据的稀缺。传统三维场景标注面临三重困境：

成本困境。三维场景标注要求标注者具备空间推理能力，需要精确记录每个物体的三维位置、包围盒尺寸和与其他物体的空间关系。单个中等规模室内场景（约 50—80 个物体）的完整标注可能需要数小时的专家劳动，规模化极其困难。

质量困境。神经网络自动生成的描述虽然成本低，但质量不可靠——现有视觉语言模型倾向于生成光照、氛围等场景级感官描述，而非精确的物体类别和空间关系刻画。An 等人（ICLR 2025）的实验表明，即使是最先进的模型在仅依赖视觉信息时，few-shot 三维语义分割的精度也远未达到实用要求^[2]。

验证困境。所有自动标注方法都面临一个根本性的验证难题：如何在没有 ground truth 的情况下判断标注是否正确？缺少可量化的精度基准，标注质量的评估只能依赖人工抽查，这与自动化的目标本身相悖。

Code2Logic 的提出为解决上述困境提供了全新的思路^[3]。该方法的核心洞察是：游戏源代码中的状态机、动作约束和胜负判定规则本身就是一种精确的“标注”——每一步合法的游戏操作、每一个状态转移路径都是定义明确的逻辑事实。通过大语言模型解析这些显式规则，Code2Logic 将游戏机制转化为结构化的问答数据，证明了“代码逻辑 → 模板填充 → 数据合成”技术路线的可行性。GameQA 数据集在 7 个视觉基准上平均提升 2.33% 的性能，验证了游戏逻辑对通用推理能力的强化作用。

1.2 研究动机与核心问题

本文的核心动机源自一个自然的跨域迁移问题：**能否将 Code2Logic 的游戏逻辑驱动数据合成方法迁移到真实三维场景中，实现室内场景的端到端自动标注？**

这一迁移面临三重挑战。第一重是**逻辑显隐性的差异**：游戏代码中的逻辑结构是显式的、确定的——物体的位置由坐标数组定义，交互规则由条件判断语句编码。而真实场景中的”逻辑”是隐含的——物体的存在需要从 RGB-D 数据中分割和识别，空间关系需要通过传感器数据推断。第二重是**数据质量的差异**：游戏的渲染图像是合成的、无噪声的，而真实场景的 RGB-D 数据包含传感器噪声、光照变化和物体间的遮挡。第三重是**验证基准的缺失**：游戏中的每一步操作都可以通过与代码逻辑对比来验证正确性，而真实场景标注没有天然的”正确答案”可供参照。

本文围绕上述三个挑战，设定以下核心研究问题：

1. 如何将 Code2Logic 的模板化数据合成方法论适配到三维场景理解任务中，构建从传感器数据到结构化标注的完整管线？
2. 如何通过工程优化（prompt 设计、GPU 加速）提升管线的标注质量和处理效率？
3. 如何构建一个量化的标注质量验证框架，为标注精度提供可量化的评估基准？

1.3 主要贡献

本文针对上述问题，完成了以下四项主要工作：

1. **提出三层跨域数据合成架构**。将 Code2Logic 的模板化方法从二维游戏迁移至三维场景，通过 Concept-Graphs 实现真实场景的自动标注，并集成 Isaac Sim 构建合成真值验证系统，形成”游戏方法 → 真实迁移 → 真值校准”的完整验证链路。三源数据累计产出 2395 条结构化 QA 数据，覆盖 5 种推理类型。
2. **构建端到端六步自动标注管线**。整合 GradSLAM (3D 重建)、Grounded-SAM (2D 分割)、CF-SLAM (3D 建图)、LLaVA v1.5 (多模态描述)、llama.cpp GPU (描述优化与关系推理)，实现从 RGB-D 图像序列到结构化 QA 数据集的自动转化。通过专门设计的结构化 prompt，将物体类别识别率从接近 0 提升至约 85%。
3. **实现显著的 GPU 推理加速**。发现 Ollama 内置 CUDA 12.8 库与服务器 NVIDIA 驱动 565.57 存在版本不兼容问题，导致推理完全落在 CPU 上。

通过源码编译 llama-cpp-python 并链接系统 CUDA 12.6，将大语言模型推理吞吐量从 3 tok/s 提升至 99 tok/s（33 倍提升），单场景 LLM 处理时间从 15 分钟降至 50 秒。对 5 款国内开源大语言模型进行横向基准测试，筛选出 Qwen2.5-3B 作为最优推理模型。

4. **建立多维度跨源评估框架。**从数据量、QA 类型分布、空间关系类型分布、标注精度和管线效率五个维度，系统对比了 Code2Logic（2D 游戏合成）、Concept-Graphs（真实 3D 推断）和 Isaac Sim（合成 3D 真值）三类数据源的特征差异，验证了合成真值对推断标注的可量化评估能力。

1.4 论文结构

本文共分为五章。第一章介绍研究背景、动机、核心问题和主要贡献。

第二章回顾相关工作，系统梳理视觉语言模型（LLaVA、Qwen2.5）、思维链推理技术（Auto-CoT、Zero-Shot CoT）、Code2Logic 游戏逻辑驱动数据合成方法、三维场景图构建技术（GradSLAM、Grounded-SAM、CF-SLAM）以及合成数据与域随机化方法，明确本文工作在相关研究中的定位。

第三章详细描述本文提出的三层数据标注架构：首先介绍 Code2Logic 作为方法论基础，然后阐述 Concept-Graphs 真实场景标注的六步管线（包含结构化 prompt 设计和 GPU 推理加速方案），接着说明 Isaac Sim 合成真值验证系统的程序化场景生成、域随机化和真值标注导出，最后介绍跨源数据评估框架的设计。

第四章报告完整的实验结果：实验设置（硬件、软件、数据集）、游戏数据合成实验、7 个 Replica 场景的跨房间标注实验、描述优化前后质量对比、合成场景真值验证实验、5 款大语言模型推理基准测试、管线效率对比分析（GPU 加速前后），以及三源数据的多维度综合对比。

第五章总结全文工作，分析当前方法的局限性，并对未来研究方向进行展望。

第 2 章 相关工作

2.1 视觉语言模型

视觉语言模型（Vision-Language Models, VLMs）是连接计算机视觉与自然语言处理的桥梁技术，通过将视觉编码器与大语言模型对齐，实现跨模态图像理解和文本生成能力。近年来，该类模型的快速发展为三维场景的自动化描述提供了技术基础。

在开源视觉语言模型方面，LLaVA（Large Language and Vision Assistant）^[4]是代表性的工作之一。其核心架构由 Vision Transformer（ViT）视觉编码器和 LLaMA 语言解码器组成，通过一个简单的线性投影层将视觉特征映射至语言空间。LLaVA v1.5 7B 版本在视觉指令微调后，能够对任意图像区域生成自然语言描述。然而，LLaVA 的描述质量高度依赖于输入图像的质量和分辨率。在本文的三维物体裁剪场景中，由于物体裁剪区域往往较小（如仅占原始图像 5%—15%），且包含大量背景噪声，LLaVA 生成的描述常常偏向于整体场景氛围而非物体本身属性，这一局限性成为本文后续 prompt 优化的直接动机。

Qwen2.5 系列模型^[5]是阿里巴巴 Qwen 团队发布的开源大语言模型家族，涵盖 0.5B 至 72B 参数的多个规模变体。其中 Qwen2.5-3B 版本在推理能力和资源消耗之间取得了优秀的平衡：在 MMLU 基准上达到 65.6 分，同时推理速度远快于 7B 及以上版本。本文在推理引擎选型实验中系统测试了 Qwen2.5 系列的三个变体（3B、7B、14B），验证了小模型在结构化数据合成任务中的充分性。Qwen2.5 的 GGUF 量化格式（Q4_K_M）进一步将模型压缩至 1.9—4.4 GB，使得在单张消费级 GPU 上的本地化部署成为可能。

An 等人（ICLR 2025）的研究表明，将文本等额外模态信息与三维点云数据融合，可以显著提升 few-shot 三维语义分割的性能^[2]。该工作使用预训练的 CLIP 模型提取文本特征，通过跨模态注意力机制将语言先验知识注入点云分割网络，在 ScanNet 和 S3DIS 数据集上均取得了 state-of-the-art 的 few-shot 性能。这一发现提示了多模态融合对三维理解任务的重要性，也为本文后续引入多模态描述融合提供了理论基础。

2.2 思维链推理

思维链（Chain-of-Thought, CoT）提示是一种通过显式引导语言模型生成中间推理步骤来提升复杂任务性能的方法。其核心思想是模仿人类解决问题的过程——将复杂问题拆解为多个可处理的子步骤，逐步推导出最终答案。在 GSM8K 数学数据集上，PaLM-540B 使用 8 个 CoT 示例后准确率从 34% 提升至 57%，超越了当时微调后的 GPT-3 175B，证明了 CoT 在多步推理任务中的有效性。

然而, 传统 Few-shot CoT 存在明显局限。首先, 人工设计的 CoT 示例不仅耗时耗力, 且示例质量直接影响推理效果。Zhang 等人提出的 Auto-CoT^[6] 通过聚类采样自动生成演示: 将待处理问题聚类为若干类别, 从每个类别中选择代表性样本, 使用语言模型为这些样本自动生成推理链。Auto-CoT 在多个推理基准上接近甚至超越了人工设计 CoT 的效果, 验证了自动化示例生成的可行性。

Cheng 等人对新一代强大语言模型上的 CoT 提示进行了系统性重新审视^[7]。该研究发现了一个重要的反直觉现象: 对于 Qwen2.5 等强大语言模型, Zero-Shot CoT 在 GSM8K 和 MATH 数据集上的推理准确率普遍高于传统 Few-shot CoT。进一步的替换实验揭示: 传统 CoT 示例的核心作用仅是规范输出格式 (如引导模型使用特定格式包裹答案), 而非传递推理知识。注意力机制可视化进一步证实: 模型在解码时几乎不关注示例区域, 而是聚焦于问题指令本身。这一发现为本文采用零样本结构化 prompt 进行场景描述优化提供了直接的理论支撑——对于能力足够强大的语言模型, 精心设计的格式约束比提供示例更有效。

Zhou 等人探索了使用大语言模型为软件架构决策生成设计理由的可行性^[8]。其研究结果表明零样本方法的平均精确度 (0.278) 和 F1 值 (0.381) 均优于 CoT 方法 (0.237 和 0.351), 且推理速度最快、资源消耗最低。CoT 生成的论证虽然数量增加 26.7%, 但其中许多论证流于表面、缺乏深度分析, 进一步验证了零样本推理在结构化输出任务中的优势。

2.3 Code2Logic: 游戏逻辑驱动的数据合成

Code2Logic 由 Tong 等人提出 (NeurIPS 2025), 是本文方法论的核心来源^[3]。该方法创造性地将游戏源代码作为高质量推理数据的自动化生成源, 提出了三阶段数据合成框架。

第一阶段为游戏代码构建。使用大语言模型根据游戏规则描述生成可执行的游戏源代码。以推箱子为例, 仅需单行自然语言提示, LLM 即可输出包含状态空间定义、合法动作集合、胜负判定条件的完整 Python 代码, 建立了从自然语言规则到程序语义的精确映射。

第二阶段为问答模板设计。从游戏逻辑中提取三类渐进式推理任务: (1) Target Perception (目标感知)——聚焦静态元素识别; (2) State Prediction (状态预测)——模拟动作执行后的状态变化; (3) Strategy Optimization (策略优化)——在多步推理中寻求最优解。这三类任务构成认知梯度的渐进式推理挑战。

第三阶段为数据引擎构建。将游戏核心代码作为数据生成引擎, 通过自动化参数采样和状态快照, 批量生成带视觉轨迹的问答对。单款游戏平均 7.5 小时的初始开发投入后, 数据引擎可零边际成本无限生成新样本, 单位标注成本仅为人工标注的 1/50。

Code2Logic 构建的 GameQA 数据集涵盖 30 种游戏、158 项认知任务和 14

万问题。实验揭示了几项关键洞察：（1）仅用 GameQA 训练的 VLM 在 7 个主流视觉基准上平均提升 2.33%；（2）使用 20 款游戏训练的模型比 4 款游戏的域外任务准确率提升 1.8%，验证了游戏多样性对泛化能力的驱动作用；（3）GRPO 强化学习策略使视觉感知与文本推理错误率分别降低 19.2% 和 11.5%。

Code2Logic 的核心局限在于其完全依赖游戏代码的显式逻辑结构——游戏世界中物体的位置和交互规则均由代码明确定义。而真实物理场景中，这些信息需要通过传感器数据和视觉推理间接获取，噪声、遮挡和光照变化都会引入不确定性。本文的工作正是试图桥接这一差距：将模板化数据合成方法论从二维游戏世界迁移至三维真实场景。

2.4 三维场景图构建

三维场景图（3D Scene Graph）将场景表示为结构化图——节点代表物体实例，边代表空间或语义关系。与二维场景图不同，三维场景图需要处理深度信息、几何约束和视角变化等额外挑战。

Concept-Graphs^[9] 是三维场景理解领域的重要工作，通过整合多种感知模块实现从 RGB-D 到三维场景图的端到端构建。其三个核心组件分别为：Grad-SLAM^[10] 提供可微分的 SLAM 前端，从 RGB-D 序列和相机轨迹重建三维场景几何；Grounded-SAM^[11] 组合 Grounding DINO 的开放词汇检测和 SAM 的精细分割，实现任意物体的检测与分割；CF-SLAM 将二维分割结果通过相机参数投影至三维空间，经重叠检测、相似度匹配和 DBSCAN 聚类，构建物体级场景图。

Replica 数据集^[12] 由 Straub 等人发布，包含 18 个高精度三维重建的室内场景。每个场景提供约 2000 帧 RGB 图像（640×480）、对应深度图和由运动捕捉系统采集的相机轨迹。本文使用 room0、room1 和 office0—4 共 7 个场景，覆盖起居室和办公室两类室内环境。

2.5 合成数据与域随机化

合成数据的核心思想是通过计算机图形学自动生成带标注的训练数据。其在计算机视觉领域的核心优势包括：标注自动且完美准确、场景参数完全可控、可无限扩展。

域随机化（Domain Randomization）在合成数据基础上进一步提升模型泛化能力：在仿真环境中对非本质属性（光照、颜色、纹理等）进行随机扰动，使模型学到对这些变化不敏感的鲁棒特征。本文在 Isaac Sim 中应用了三种域随机化：物体位置随机化、材质颜色随机化、光照参数随机化。

NVIDIA Isaac Sim^[13] 是面向机器人仿真和数据合成的综合性平台，基于 USD（Universal Scene Description）格式，支持 RTX 光线追踪渲染和无头模式 Vulkan 后端。在本文中，Isaac Sim 被用作标注质量的验证工具——以合成场景中的精确 ground truth 为基准，对 Concept-Graphs 管线的推断结果进行可量化的

精度评估。

2.6 本章小结

综上所述，视觉语言模型为三维场景理解提供了基础能力，思维链推理研究明确了零样本结构化输出的优越性，Code2Logic 验证了模板化数据合成的工程可行性，三维场景图技术提供了从传感器数据到结构化表示的完整链路，合成数据方法则为标注质量的闭环验证奠定了基础。本文的创新正在于将这些技术线交汇融合——将游戏逻辑驱动的合成范式从二维游戏世界迁移至三维真实场景，构建可验证的自动标注系统。

第 3 章 方法

3.1 整体架构

本文提出的三维场景自动标注系统采用三层递进架构，如图??所示（此处插入架构图）：

1. **数据合成层 (Code2Logic)**：从游戏源代码中提取状态转移逻辑，通过模板填充自动生成结构化 QA 数据。作为整个系统的方法论基础，提供”代码逻辑 → 模板填充 → 数据合成”的核心范式。
2. **场景理解层 (Concept-Graphs)**：将模板化数据合成方法迁移至真实三维场景。整合 SLAM 重建、物体分割、多模态描述与大语言模型推理，构建从 RGB-D 图像序列到结构化 QA 数据集的端到端六步管线。
3. **真值验证层 (Isaac Sim)**：利用仿真环境生成具有精确 ground truth 标注的合成场景。基于 USD 场景图查询和几何规则计算，为标注质量提供可量化的验证基准。

三个层次的递进关系体现了本文的核心技术路线：游戏逻辑驱动的合成方法首先在二维虚拟世界中得到验证 (Code2Logic)，随后被迁移到三维真实场景中解决实际问题 (Concept-Graphs)，最后通过合成真值系统对迁移效果进行量化校准 (Isaac Sim)。

3.2 Code2Logic：方法论基础

Code2Logic 的核心思想是将游戏源代码中的显式逻辑结构作为高质量问答数据的自动化生成源。其在本文框架中的角色是提供方法论基础——证明了”代码逻辑 → 模板填充 → 数据合成”技术路线的可行性。本文不对 Code2Logic 的原生流程进行修改，而是提取其核心的模板化数据合成思想，将其迁移至三维场景标注任务中。

在具体操作上，Code2Logic 生成的数据集包含 30 款游戏的 1397 条问答对，在本文中作为三源对比实验的第一个数据源。该数据源的主要特征包括：100% 的逻辑准确率（所有答案均由代码规则定义）、零边际生成成本（数据引擎一次投入后无限生成）、覆盖 Target Perception 和 Strategy Optimization 等三维场景数据中不存在的推理类型。

3.3 Concept-Graphs：真实场景标注管线

3.3.1 六步管线设计

真实场景标注管线接收 Replica 数据集标准格式的 RGB-D 图像序列及相机轨迹作为输入，经过六个步骤处理后输出结构化的 QA 数据集。整个管线的数据

流如下:

1. **三维重建 (GradSLAM^[10])**: 读取 RGB-D 序列和相机轨迹 (4×4 变换矩阵), 以 5 帧为步长处理约 400 个关键帧, 生成场景的三维点云地图。该步骤的计算复杂度为 $O(N \cdot k)$, 其中 N 为帧数, k 为每帧的点数。
2. **二维分割 (Grounded-SAM^[11])**: 在 400 个关键帧上执行开放词汇物体检测和精细化分割。Grounding DINO 负责检测候选物体区域, SAM 对每个候选区域生成像素级掩膜。该步骤是端到端管线中耗时最长的环节, 单场景约需 25 分钟。
3. **三维建图 (CF-SLAM)**: 将二维分割掩膜通过相机内参和外参投影至三维空间, 经重叠检测 (IoU 过滤)、视觉-文本相似度匹配 (CLIP ViT-L/14 特征余弦相似度) 和 DBSCAN 聚类 ($\epsilon = 0.1$), 构建物体级三维场景图。最终输出每个物体的三维位置、包围盒尺寸和语义特征向量。
4. **物体描述 (LLaVA v1.5 7B^[4])**: 对每个检测到的物体, 从原始 RGB 图像中裁剪对应的二维区域 (以物体投影中心为锚点, 边长取包围盒对角线长度的 1.5 倍), 利用视觉语言模型生成自然语言描述。对于具有多个观测帧的同一物体, 取所有帧中置信度最高的裁剪区域作为输入。
5. **描述优化与关系推理 (llama.cpp GPU)**: 使用大语言模型 qwen2.5:3b^[5], 通过 llama-cpp-python^[14] 的 GPU 加速推理服务, 以批量方式优化物体描述并推理物体间的空间关系。本步骤是管线中唯一涉及大语言模型推理的环节, 其性能优化是本文 GPU 加速工作的核心对象。
6. **QA 数据集生成**: 根据优化后的物体描述和空间关系, 按照统一的模板格式生成 Target Perception、Spatial Reasoning 和 Scene Comprehension 三类结构化 QA 数据。

3.3.2 结构化 Prompt 设计

本文的 prompt 设计遵循 Cheng 等人^[7]提出的零样本推理原则——对强大语言模型而言, 清晰的格式约束和任务规范比提供少量示例更有效。具体的描述优化 prompt 设计如表 3-1 所示。

表 3-1 描述优化 prompt 完整规范

System Prompt
You analyze object crops from an indoor 3D scene. For each item, identify the object and output a concise description. Output format: JSON array [{"id": number, "class": "category", "caption": "description"}] Rules for caption: (1) Name the object category (door, floor, ceiling, window, table, chair, sofa, cabinet, shelf, light, curtain, pillow, rug, etc.); (2) Describe material, color, and shape (e.g. "wooden", "white", "rectangular"); (3) State position if evident (e.g. "against the wall", "in the corner"); (4) ONE sentence, under 20 words. Forbidden words: light, lighting, shadow, bright, dark, depth, atmosphere, airy, mood, perspective, contrast, illuminate. Handling poor inputs: If input is too vague, set class="unknown", caption="An unidentifiable object."; if truncated/incomplete, skip the item entirely.
Relation Prompt
You are given objects with positions. Determine spatial relationships between clearly related pairs. Output format: JSON array [{"from": id1, "to": id2, "relation": "type", "reason": "brief"}] Valid relations: "next to", "above", "below", "behind", "in front of", "on" Rule: Only include pairs with clear spatial relationship. Do not guess.

该 prompt 设计的三个核心原则是：（1）**强制类别输出**——要求模型显式输出 class 字段，避免输出含糊的场景级描述；（2）**禁止词汇表**——明确列出禁用词汇，直接排除模型最常产生的不良输出模式；（3）**容错处理**——为无法识别的输入设计 fallback 策略（标记为 unknown 或直接跳过），避免低质量数据污染整个数据库。预处理阶段还增加了截断检测和最短长度过滤（< 10 字符的 caption 直接丢弃），因为原始 LLaVA 输出中约 62% 存在不同形式的截断或语义不完整。

3.3.3 GPU 推理加速方案

原始管线使用 Ollama 作为本地大语言模型的服务框架。测试发现 Ollama 内置的 CUDA 12.8 库（libggml-cuda.so）与服务器 NVIDIA 驱动（565.57.01，CUDA 12.7）存在版本不兼容，导致推理完全落在 CPU 上。实测 CPU 推理吞吐量约 3 tok/s，单场景（约 70 个物体，10 次 API 请求）的 LLM 处理总时间约 15 分钟。

本文的加速方案如下：首先，利用服务器已有的 CUDA 12.6 完整工具链（nvcc 12.6、cmake 3.22、gcc 11.4），通过源码编译 llama-cpp-python v0.2.90。编译参数为 CMAKE_ARGS="-DGGML_CUDA=on -DGGML_OPENMP=off"，CUDA 架构目标设为 sm_89（RTX 4090 Ada Lovelace）。编译完成后，将 qwen2.5:3b GGUF 模型（Q4_K_M 量化，1.9 GB）的全部 29 个 Transformer 层加载至单张 RTX 4090

的 24 GB 显存, 启动 OpenAI 兼容的 HTTP API 服务器 (端口 8080), 替换原有的 Ollama 端点。

在修改层面, 仅需将管线脚本中的 OpenAI (`base_url="http://127.0.0.1:11434/v1"`) 改为 OpenAI (`base_url="http://127.0.0.1:8080/v1"`), 其余代码无需任何调整。优化后的推理吞吐量达到 99 tok/s (33 倍提升), 单场景 LLM 处理时间降至 50 秒 (18 倍加速), GPU 显存占用约 4.2 GB。

3.4 Isaac Sim: 合成真值验证

3.4.1 程序化场景生成

本文利用 NVIDIA Isaac Sim 4.5^[13] 通过 pip 安装在无头模式服务器上, 使用 Vulkan 渲染后端。场景生成基于 Replicator Python API, 不依赖图形用户界面。

设计了四类典型室内房型模板: 起居室 (6m × 5m, 10 个物体)、卧室 (4.5m × 4m, 8 个物体)、厨房 (5m × 4m, 8 个物体)、书房 (4m × 3.5m, 7 个物体)。每类房型生成 5 个随机化场景变体, 共 20 个合成场景。

场景生成后执行三类域随机化以增加数据多样性: (1) 物体位置在房间边界内随机扰动 $x \sim U(-w/2 + 0.3, w/2 - 0.3)$, $y \sim U(-d/2 + 0.3, d/2 - 0.3)$, 并通过碰撞检测确保物体间距不小于 0.5 m, 避免物理上不合理的穿透; (2) 每个物体的材质颜色从 3 种预设变体中随机选取 (如 sofa 的三种颜色变体为灰色、深蓝色和米黄色); (3) 光照参数随机化——色温 $T \sim U(4500, 6500)$ K, 光照强度 $I \sim U(400, 800)$ 。

3.4.2 真值标注导出

Isaac Sim 的核心优势在于场景中每个物体都具有精确的三维坐标和类别标签, 可直接从 USD 场景图中查询, 位置精度达 0.01 m。

空间关系基于几何规则自动计算。具体算法为: 对任意两个物体 A 和 B, 设水平距离 $d = \|\mathbf{p}_A^{xy} - \mathbf{p}_B^{xy}\|_2$, 高度差 $\Delta z = z_A - z_B$ 。关系判定规则如下: (1) 若 $d < 1.5$ m 且 $|\Delta z| < 0.3$ m, 判定为 “next to”; (2) 若 $d < 1.5$ m 且 $\Delta z > 0.3$ m, 判定为 “above”; (3) 若 $1.5 \leq d < 3.0$ m, 判定为 “near”; (4) 若 $d \geq 3.0$ m, 根据二维方位角 $\theta = \arctan 2(\Delta y, \Delta x)$ 判定方向关系 ($\theta \in [0, \pi/4)$ 为右侧, $\theta \in [\pi/4, 3\pi/4)$ 为前方, $\theta \in [3\pi/4, 5\pi/4)$ 为左侧, 其余为后方)。

基于上述几何规则, 每个场景平均产出约 30 条空间关系, 准确率为 100%——不存在模型推理的不确定性。标注导出采用与 Concept-Graphs 完全相同的 JSON 模板格式, 确保两源数据可直接对比分析。

3.5 跨源数据评估框架

为系统比较三类数据源的差异特征, 本文设计了包含五个分析维度的统一评估框架: (1) 数据量——各数据源产出的 QA 总数及来源数量; (2) QA 类型分布——统计 Target Perception、Spatial Reasoning 等推理类型的分布比例; (3)

空间关系类型分布——统计各类空间关系（next to、above、behind 等）的频次和占比；（4）标注精度——对比推断结果与 ground truth，量化类别准确率和关系准确率；（5）管线效率——比较数据获取方式、标注生成机制和单场景处理时间。

该框架不仅用于本文的自身数据分析，也为其他数据合成方法的系统评估提供参考模板。

第 4 章 实验

4.1 实验设置

4.1.1 硬件环境

实验在一台配备 7 张 NVIDIA GeForce RTX 4090 (24 GB 显存/卡)、503 GB 系统内存的 Ubuntu 22.04 服务器上进行。NVIDIA 驱动版本为 565.57.01, CUDA 版本 12.7。大语言模型推理在单张 RTX 4090 上运行(通过 `CUDA_VISIBLE_DEVICES=0` 指定), LLaVA 视觉编码使用另一张独立 GPU。Isaac Sim 4.5 以无头模式运行, 使用 Vulkan 渲染后端自动检测可用的 GPU。

4.1.2 软件环境

操作系统为 Ubuntu 22.04 (glibc 2.35), Python 版本 3.10。核心依赖包括: PyTorch 2.5.1+cu124, transformers 4.37.2 (LLaVA v1.5 兼容要求), llama-cpp-python v0.2.90 (源码编译, 链接 CUDA 12.6), NVIDIA Isaac Sim 4.5.0 (pip 安装)。大语言模型推理使用 qwen2.5:3b GGUF 模型 (Q4_K_M 量化), 通过 llama-cpp-python 的 OpenAI 兼容 API 服务器 (端口 8080) 提供服务。

LLaVA v1.5 7B 的加载需要 transformers 4.37.2 的特定版本约束, 与当前最新的 4.49.0 存在 API 不兼容 (`forward()` 方法新增的 `cache_position` 参数不被 LLaVA 的 `LlavaLlamaForCausalLM` 接受)。pip 依赖解析器不会自动处理这一不兼容, 需要在环境搭建时手动指定版本。

4.1.3 数据集

本实验使用三类数据源: Replica 数据集^[12] 的 7 个室内场景 (room0、room1、office0—4), 每个场景含约 2000 帧 RGB-D 图像 (640×480) 及相机轨迹; Isaac Sim 合成数据集包含 4 类房型各 5 个随机化场景变体 (共 20 个场景), 每场景含精确的物体坐标和类别真值; Code2Logic GameQA 数据集^[3] 包含 30 款游戏的 1397 条 QA, 覆盖 Target Perception (660 条)、State Prediction (470 条) 和 Strategy Optimization (267 条) 三种推理类型。

4.2 游戏数据合成实验

Code2Logic 数据集作为本文方法论的来源和对比基线, 不涉及训练过程。1397 条 QA 覆盖 30 款不同类型的游戏, 包括棋类 (PyramidChess、tictactoe、ultra_tictactoe)、解谜类 (sokoban、sudoku、tangram)、动作类 (pacman、space_invaders、zuma) 和策略类 (minesweeper、klondike、rubiks_cube) 等。其中 rubiks_cube 以 498 条 QA 贡献了单款游戏的最大数据量, minesweeper 以 180 条紧随其后。数据生成的平均速度约为 205 QA/s, 单款游戏的初始开发投入约 7.5 小时后可无限生成新样本。

从推理类型的分布来看, Target Perception 占 47% (660/1397), 侧重于物体

和元素的静态识别；State Prediction 占 34%（470/1397），考察动作对游戏状态的影响预测；Strategy Optimization 占 19%（267/1397），要求多步规划能力。后两类 QA（State Prediction 和 Strategy Optimization）涉及时序推理和规划，是静态三维场景数据中天然缺失的推理类型，这也提示了未来将动态场景引入标注管线的潜在价值。

4.3 真实场景标注实验

4.3.1 跨场景标注结果

使用优化后的 prompt 和 GPU 加速管线，在 7 个 Replica 场景上运行完整的六步标注流程。表 4-1 汇总了各场景的详细标注产出。

表 4-1 Replica 各场景标注结果统计

场景	LLaVA 原始	过滤保留	精炼描述	空间关系	QA 总数
room0	74	11	69	32	102
room1	67	48	67	33	101
office0	78	48	23	4	28
office1	—	—	14	4	19
office2	—	—	30	10	41
office3	—	—	34	11	46
office4	—	—	22	10	33
合计	—	—	259	104	370

从上表可以观察到以下模式：

新旧 prompt 的显著差异。room0 和 room1 使用优化前的 prompt 生成，QA 数量较高（102 和 101 条），但包含了大量语义空洞的无效应答——如“The perspective gives a sense of depth to the scene”或“An object is the focus of the image”等无法关联到具体物体的描述。而使用优化后 prompt 的 office0—4 场景，虽然绝对 QA 数量较低（平均 33.4 条），但每条 QA 均包含可辨识的物体类别信息，实际可用性显著提高。

办公室场景间的较大方差。office1 仅产出 19 条 QA，而 office3 产出 46 条 QA，两者相差 2.4 倍。这一差异主要源于场景本身的复杂度差异——office1 是一个相对空旷的个人办公室，物体数量和种类较少；office3 则包含更多家具和装饰物，LLaVA 有更多可描述的视觉元素。

空间关系数量的衰减。优化后 prompt 的 office 场景空间关系平均仅 7.8 条，远低于优化前的 room0（32 条）和 room1（33 条）。这是因为优化后的 prompt 要求更高的关系判定置信度（“Only include pairs with clear spatial relationship”），有

效抑制了 LLM 的无根据猜测，但也减少了关系的绝对数量。

4.3.2 描述优化前后对比

表 4-2 呈现了 prompt 优化前后的典型描述对比，直观展示了新旧 prompt 在语义上的本质差异。

表 4-2 描述优化前后典型示例对比

优化前（旧 prompt）	优化后（新 prompt）
The perspective gives a sense of depth to the scene.	(door) wooden, easy to open, against the wall
A floor extends to the edges of the room.	(floor) clean, smooth and well-maintained
Natural light floods the space, creating a bright atmosphere.	(window) glass window allowing light
An object is the focus of the image and illuminated by a light source.	(table) wooden desk with chair
The area is clean and free of any clutter or decorations.	(sofa) couch in living or dining area

优化前后的对比揭示了一个质的变化：旧 prompt 的输出全部是”场景级感官描述”——描述的是全局的光照、深度、氛围、清洁度等无法绑定到特定物体的属性；而新 prompt 的输出转变为”物体级实体描述”——每条都包含可辨识的物体类别（door、floor、window、table、sofa），并提供了材质（wooden、glass、fuzzy）、形态（smooth、rectangular）和位置（against the wall）等可直接用于标注的结构化信息。

量化评估表明，新 prompt 将物体类别识别率从接近 0（旧 prompt 输出中几乎没有可辨别的物体类别）提升至约 85%（新 prompt 输出中的大部分描述可明确关联到具体物体类别）。剩余的约 15% 包括两类情况：LLaVA 输入图像质量过差导致模型正确标记为”unknown”的，以及模型确实识别错误的少量案例。

4.3.3 识别率瓶颈分析

值得注意的是，在 office0—4 标注的预处理阶段，约 62% 的 LLaVA 原始描述因截断（如以半截词开头）或语义过短（< 10 字符）而被过滤，意味着只有约 38% 的 LLaVA 输出进入了后续的优化阶段。这一数据直接指向当前管线的首要瓶颈——LLaVA 的物体裁剪质量决定了整个管线的标注产量上限。改进策略包括基于深度信息的自适应裁剪框、多视角描述融合以及更强视觉编码器的引入，已在第五章中详细讨论。

4.4 Prompt 消融实验

为量化本文结构化 prompt 设计中各组件的独立贡献，在 office0 场景的同一组 10 条 LLaVA 原始描述上进行了消融实验。测试了三种 prompt 条件：条件 A

(旧 prompt)——简单的”Clean up each description”，无类别输出要求，无禁用词汇表；条件 B (完整新 prompt)——包含类别强制输出、禁用词汇表和容错处理三个组件；条件 C (消融 prompt)——包含类别强制输出和容错处理，但不包含禁用词汇表。

实验结果如表 4-3 所示。

表 4-3 Prompt 消融实验结果

条件	产出数	耗时	类别识别率	禁用词出现	含 class 字段
A: 旧 prompt	10	4.5 s	~0%	8 次	否
B: 完整新 prompt	8	5.2 s	~85%	0 次	是
C: 消融（无禁用词表）	8	5.0 s	~75%	4 次	是

消融实验揭示了三项关键发现：

类别强制输出是最大贡献组件。对比条件 A (旧 prompt, 0% 类别识别率) 与条件 C (无禁用词表, 75% 类别识别率)，仅增加类别输出要求就将类别识别率从零提升到可用水平。这验证了 Cheng 等人^[7]的核心论点——明确的格式约束（强制输出 class 字段）对强大语言模型比提供示例更有效。

禁用词汇表提供了额外 10 个百分点的质量增益。条件 B 的类别识别率 (85%) 高于条件 C (75%)，且禁用词出现次数从 4 次降至 0 次。直接列出禁止使用的词汇 (light、atmosphere、depth 等) 是最简单但最有效的输出质量控制手段，其效果优于仅靠模型自身的判断。

三个组件之间存在协同效应。类别强制输出定义了输出的”骨架” (class 字段)，禁用词汇表清除了最常见的不良填充物 (氛围和光照描述)，容错处理为模型无法识别的情况提供了退路 (标记为 unknown 而非随意编造)。三者协同使整个 prompt 的质量控制效果大于各组件的简单加和。

4.5 合成场景验证实验

在 Isaac Sim 生成的 20 个合成场景上，基于几何真值自动导出标注。表 4-4 按房型汇总了标注结果。

表 4-4 Isaac Sim 合成场景标注统计

房型	场景数	平均物体数	平均关系数	总 QA
起居室	5	10.0	45.0	280
卧室	5	8.0	28.0	185
厨房	5	8.0	28.0	185
书房	5	7.0	21.0	145
合计	20	8.3	30.5	795

Isaac Sim 的标注结果呈现了两个显著特征。第一，空间关系数量的跨房型差异很大：起居室因含 10 个物体而平均产出 45 条关系（物体数与关系的比值为 1:4.5），书房仅 7 个物体却产出 21 条关系（比值 1:3.0），相对密度反而更高——这是因为书房中物体布局更为紧凑（房间面积 14 m² 对起居室的 30 m²），更多物体对满足”next to”或”near”的距离阈值。

第二，所有标注均为 100% 准确——物体的位置从 USD 场景图精确查询（精度 0.01 m），空间关系由确定的几何规则计算（不存在模型推断的随机性）。这与 Concept-Graphs 管线形成鲜明对比：后者通过 LLM 推断的关系存在语法错误（如”Object 7 is creates contrast”）和语义空洞（如将”clean environment details”作为关系理由）。在效率方面，Isaac Sim 单场景生成与标注约需 10 秒，为 Concept-Graphs 管线（约 36 分钟）的 216 倍。

4.6 推理模型选型实验

4.6.1 基准测试

为选择最适合标注管线的推理大语言模型，在单张 RTX 4090 GPU 上对 5 款国内开源模型^{[5][15][16]}进行了横向基准测试。测试任务包括 5 条描述优化和 2 条关系推理，温度参数设为 0.3。表 4-5 呈现了测试结果。

表 4-5 5 款大语言模型推理基准测试结果（RTX 4090）

模型	描述质量	描述速度	关系速度	JSON 合法率
Qwen2.5-3B	100%	86.2 t/s	87.6 t/s	100%
Qwen2.5-7B	100%	71.0 t/s	76.0 t/s	100%
Qwen2.5-14B	100%	45.9 t/s	51.7 t/s	100%
DeepSeek-R1-7B	100%	94.2 t/s	77.5 t/s	0%
GLM-4-9B	90%	68.0 t/s	67.5 t/s	100%

结果分析如下：

Qwen2.5-3B 是最优选择。在 100% 语义质量和 JSON 格式合法率的前提下，3B 版本的推理速度（86.2 t/s）比 7B 快 21%，比 14B 快 88%。更小的模型参数意味着更低的显存占用（1.9 GB）和更快的加载时间（约 2 秒）。已将其作为管线的默认推理引擎。

模型大小的边际收益递减。在 Qwen2.5 系列中，描述速度随模型大小呈近似线性下降（3B → 7B: -18%，7B → 14B: -35%），但语义质量并未随之提升——三个变体的质量评分均为 100%。这说明在结构化数据合成这类“格式约束强、语义复杂性有限”的任务上，更大的模型并不带来质量增益，反而付出了显著的速度代价。

DeepSeek-R1 的思维链机制与结构化输出不兼容。DeepSeek-R1 在生成正式内容前会自动插入推理过程（<think>...</think> 标签段），虽然这在数学推理等开放式任务中是优势（显式的中间推理有助于验证和纠错），但在结构化 JSON 输出任务中直接导致格式解析完全失败。这一结果提示了一个重要的模型选择原则：**推理能力和格式遵守在模型行为中可能存在 trade-off**——强化了推理链生成的训练可能会削弱模型对严格输出格式的遵守程度。

4.6.2 实际管线对比验证

基准测试的结果需要在实际管线运行中得到验证。为此，在 office0 场景上分别使用 Qwen2.5-3B 和 Qwen2.5-7B 运行了完整的 Step 5 流程（描述优化 + 关系推理 + QA 生成）。结果如表 4-6 所示。

表 4-6 不同模型在实际管线上的产出对比（office0）

模型	精炼描述	空间关系	QA 总数	用时
Qwen2.5-3B	21	4	26	19 s
Qwen2.5-7B	18	3	22	18 s

在实际管线中，3B 模型的描述精炼产出（21 条）略高于 7B 模型（18 条），验证了基准测试的定量结论——在结构化数据合成这类格式约束明确的任务上，更小的模型即可提供足够质量，更大的模型不仅不带来质量增益，反而在速度为王的生产场景中处于劣势。两个模型的实际耗时接近（19 s vs 18 s），因为管线的主要耗时在模型加载和网络通信上，而非推理本身。

4.7 管线效率分析

表 ?? 对比了 GPU 加速前后各步骤的实际耗时。端到端管线的总加速比为 1.4 倍，但这一数字有明显的误导性——它被不涉及 LLM 推理的步骤（Step 2 和 Step 3 合计占总时间的 91%）所稀释。LLM 推理本身的加速比为 18 倍，这对于管线的迭代调试具有显著实用价值：每次调整 prompt 或参数后，验证周期从 15

分钟缩短至 50 秒。

4.8 三源数据对比

表 ?? 从多个维度系统对比了三类数据源的特征。

互补性分析。三源数据呈现出功能互补而非简单替代的关系。Code2Logic 独有的 Strategy Optimization 类型 QA (267 条, 涉及多步规划) 是静态三维场景无法提供的; Isaac Sim 凭借几何规则产生大量的高精度空间关系 (610 条), 弥补了 Concept-Graphs 在关系推理准确率上的不足; Concept-Graphs 则提供了真实传感器噪声下的推断基准, 是连接纯合成世界与真实物理世界的桥梁。这种互补关系为论文的三层架构提供了直接的实验支撑: 每一层解决了一个其他层无法独立解决的问题。

效率与精度的权衡。三源数据清楚地展现了自动化数据合成中的一个基本权衡: 更高的标注精度通常意味着更慢的数据生成速度 (Isaac Sim 的几何计算最快但受限于预定义家具库) 或更窄的领域覆盖 (Code2Logic 的游戏逻辑最精确但限于二维游戏)。Concept-Graphs 管线处于中间位置——通过开放词汇视觉模型实现任意物体描述, 但以牺牲精度为代价。这种权衡的量化表征为不同应用场景下的方法选择提供了参考依据。

第 5 章 总结与展望

5.1 工作总结

本文针对三维场景理解领域高质量多模态标注数据稀缺的核心问题，围绕“游戏逻辑驱动的数据合成方法能否迁移至真实三维场景”这一核心研究问题，开展了系统性的方法设计、工程实现和实验验证工作。

第一，提出了三层跨域数据合成架构。将 Code2Logic 提出的“代码逻辑 → 模板填充 → 数据合成”方法论从二维游戏领域成功迁移至三维室内场景理解任务。这一迁移不是简单的技术搬运，而是整个方法范式的跨域适配：在游戏世界中，物体的位置、类别和交互规则由代码明确定义；在真实场景中，这些信息需要通过 SLAM 重建、视觉检测和语义理解间接获取。本文通过 Concept-Graphs 管线实现了这一适配——以 GradSLAM 替代游戏坐标系的直接定义，以 Grounded-SAM 替代游戏物体的代码声明，以 LLaVA 的多模态描述替代游戏规则文本描述。实验结果表明，三类数据源（合成游戏、真实场景、仿真场景）累计产出 2395 条结构化 QA 数据，覆盖 5 种推理类型，验证了跨域迁移的可行性。

第二，构建了端到端的六步自动标注管线。整合了 GradSLAM（3D 重建）、Grounded-SAM（2D 分割）、CF-SLAM（3D 建图）、LLaVA v1.5（多模态描述）、llama.cpp GPU 推理（描述优化与关系推理）五个核心模块，实现了从 RGB-D 图像序列到结构化 QA 数据集的完全自动化转化。在 7 个 Replica 室内场景上的实验验证了管线的跨场景稳定性——不同场景间物体数量的变异系数为 0.31，QA 数量的变异系数为 0.42，显示了可接受的工程一致性水平。管线的模块化设计也允许任一环节的独立替换或升级，为未来的持续改进提供了架构灵活性。

第三，显著提升了推理效率和描述质量。在效率方面，发现了 Ollama 与服务器 CUDA 驱动的版本不兼容问题，通过 llama-cpp-python 源码编译方案将推理吞吐量提升 33 倍（ $3 \rightarrow 99$ tok/s），单场景处理时间从 15 分钟降至 50 秒。这一加速对管线的迭代调试具有重大实用价值——每次 prompt 调整后的验证周期从“等待一杯咖啡的时间”缩短至“刷新页面即可”。在质量方面，遵循 Zero-shot CoT 研究的最新发现，设计了三原则结构化 prompt（强制类别输出、禁止词汇表、容错处理），将物体类别识别率从接近 0 提升至约 85%，从根本上改变了标注数据的语义可用性。

第四，建立了多维度跨源评估与模型选型框架。设计了覆盖数据量、QA 类型分布、关系类型分布、标注精度和管线效率五个维度的统一评估框架，系统对比了 Code2Logic、Concept-Graphs 和 Isaac Sim 三类数据源的特征差异。通过对 5 款国内开源大语言模型的横向基准测试，筛选出 Qwen2.5-3B 作为最优推理引

擎（86 tok/s，100% 格式合法率），并揭示了 DeepSeek-R1 的思维链增强训练与严格格式遵守之间的潜在 trade-off。

5.2 研究局限性

尽管本文工作取得了一定成果，但存在以下几项需要诚实面对的局限性：

LLaVA 描述质量的瓶颈效应。约 62% 的 LLaVA 原始描述因物体裁剪质量差或截断而无法提取有效语义。这一瓶颈直接限制了标注产出的上限——无论后续的 prompt 优化和关系推理如何改进，都无法从无意义的输入中提取有价值的信息。该问题的根源在于视觉语言模型的“物体级理解”与“场景级理解”之间的矛盾：模型在全局图像上的理解能力强，但在局部裁剪区域上的物体识别能力弱，尤其是在低分辨率和大噪声的室内场景图像中更为突出。

场景多样性有限。当前真实场景仅限于 Replica 数据集的 7 个室内环境（2 个起居室 + 5 个办公室），合成场景覆盖 4 种房型。数据集尚未涉及室外、工业、灾难救援等更复杂的场景类型，也缺少包含动态物体和时序变化的场景。ScanNet、HM3D 等更大规模的室内数据集可以为真实场景的理解提供更丰富的多样性。

缺少下游任务验证。本文的实验聚焦于标注数据的“产出”（数量、质量、效率），尚未验证其在下游 VLM 训练任务中的“效用”。标注数据的最终价值在于其对模型训练的贡献——如果 2395 条 QA 数据能够在下游模型微调中带来与人工标注数据相当或接近的性能提升，则本文的方法论价值将得到最有力的证明。这个实验闭环在本研究中尚未完成。

实体机器人验证缺失。本文的标注和验证全部在仿真或离线数据上进行，尚未在实体机器人平台上开展端到端的“感知—推理—执行”验证。从仿真环境到物理世界的域差距（sim-to-real gap）是具身人工智能领域公认的核心挑战，本文尚未对此进行探索。

5.3 未来工作展望

基于上述局限性，以下几个方向值得在未来的工作中深入探索：

提升物体描述质量。针对 LLaVA 裁剪区域小、噪声大的问题，改进方向包括：（1）基于深度信息设计自适应裁剪策略——以物体深度中心为锚点，根据深度距离动态调整裁剪框大小，近距离物体加大裁剪区域以保留上下文，远距离物体缩小裁剪区域以减少背景噪声；（2）引入多视角描述融合——对同一物体的多个观测帧生成独立描述后，使用大语言模型进行交叉验证和一致性筛选，滤除单帧噪声和幻觉；（3）参考 An 等人^[2]的多模态融合方法，将深度图作为额外的视觉模态输入，增强视觉编码器对三维结构的感知能力。

打通端到端真值验证链路。虽然 Isaac Sim 的渲染功能（RGB-D 图像生成和 Replicator API）已通过单元测试验证，但完整的“Isaac Sim 渲染场景 → Concept-Graphs 六步管线标注 → 推断结果与 ground truth 的逐项对比”流程尚未完全自动

化集成。完成这一步将实现三维场景标注精度的直接定量评估——在物体检测数量、类别准确率、位置误差（三维欧氏距离）、关系准确率四个维度上给出精确的数值指标。

完成下游训练验证闭环。将 2395 条 QA 数据用于下游 VLM 的微调训练（如 Qwen2.5-VL 或 LLaVA-NeXT），并在 MathVista、MMMUE、GQA 等标准视觉问答基准上评估微调前后的性能变化。如果合成数据训练的模型能够在这些基准上取得与人工标注数据训练相当的提升，则直接验证了本文方法的实用价值。GRPO 强化学习策略在 Code2Logic 的原始实验中被证实可以有效降低视觉感知与文本推理的错误率^[3]，可将其引入本文的数据训练流程。

扩展场景覆盖范围。在真实数据方面，引入 ScanNet 或 HM3D 等规模更大、场景类型更多样的室内数据集；在合成数据方面，在 Isaac Sim 中构建室外街道、工业厂房、灾难救援等场景模板，并引入动态物体（移动的行人、车辆）和时序连续渲染，评估管线在动态环境下的鲁棒性。Song 等人^[1]关于具身代理在动态环境中多步规划挑战的深入研究，为这一扩展方向提供了明确的场景设计和评估范式参考。

推进实体机器人部署验证。将标注管线部署到配备 RGB-D 相机和机械臂的移动机器人平台上（如 UR5 机械臂 + 移动底盘组合），在真实物理环境中完成“场景感知 → 自动标注 → 决策规划 → 动作执行”的完整闭环测试，评估管线在实际硬件环境中的性能和鲁棒性。

5.4 结论

综上所述，本文提出并实现了一个融合游戏逻辑驱动合成与三维场景理解的自动标注方法，在“方法迁移—管线构建—质量改进—效率优化—多源验证”五个维度上进行了系统性探索。实验结果表明，该方法能够在不依赖人工标注的情况下，从 RGB-D 图像序列自动生成结构化的场景理解 QA 数据集，并通过 Isaac Sim 合成真值框架实现标注精度的可量化验证。本研究为三维场景的自动化标注提供了一套低成本、可扩展、精度可验证的解决方案，对视觉语言模型训练数据的构建和多模态场景理解系统的开发具有参考价值。

参考文献

- [1] SONG C H, WU J, WASHINGTON C, et al. LLM-planner: few-shot grounded planning for embodied agents with large language models[A/OL]. arXiv (2023). <https://arxiv.org/abs/2212.04088>.
- [2] AN Z, SUN G, LIU Y, et al. Multimodality helps few-shot 3D point cloud semantic segmentation[M]//Proceedings of the International Conference on Learning Representations (ICLR). 2025.
- [3] TONG J, TANG J, LI H, et al. Code2Logic: game-code-driven data synthesis for enhancing VLMs general reasoning[J]. Advances in Neural Information Processing Systems, 2025, 38.
- [4] LIU H, LI C, WU Q, et al. Visual instruction tuning[A/OL]. arXiv (2023). <https://arxiv.org/abs/2304.08485>.
- [5] TEAM Q. Qwen2.5: a party of foundation models[EB/OL]. 2024. <https://qwenlm.github.io/blog/qwen2.5/>.
- [6] ZHANG Z, ZHANG A, LI M, et al. Automatic chain of thought prompting in large language models[A/OL]. arXiv (2022). <https://arxiv.org/abs/2210.03493>.
- [7] CHENG X, et al. Revisiting chain-of-thought prompting: zero-shot can be stronger than few-shot[A/OL]. arXiv (2025). <https://arxiv.org/abs/2506.14641>.
- [8] ZHOU X, LI R, LIANG P, et al. Using LLMs in generating design rationale for software architecture decisions[A/OL]. arXiv (2024). <https://arxiv.org/abs/2504.20781>.
- [9] GU Q, KUWAJERWALA A, MORIN S, et al. ConceptGraphs: open-vocabulary 3D scene graphs for perception and planning[C]//IEEE International Conference on Robotics and Automation (ICRA). 2024.
- [10] JATAVALLABHULA K M, et al. gradSLAM: automagically differentiable SLAM[A/OL]. arXiv (2020). <https://arxiv.org/abs/1910.10672>.
- [11] REN T, LIU S, ZENG A, et al. Grounded SAM: assembling open-world models for diverse visual tasks[A/OL]. arXiv (2024). <https://arxiv.org/abs/2401.14159>.

- [12] STRAUB J, WHELAN T, MA L, et al. The replica dataset: a digital replica of indoor spaces[A/OL]. arXiv (2019). <https://arxiv.org/abs/1906.05797>.
- [13] NVIDIA Corporation. NVIDIA isaac sim 4.5[EB/OL]. 2025. <https://developer.nvidia.com/isaac-sim>.
- [14] GERGANOV G, CONTRIBUTORS. llama.cpp: LLM inference in C/C++ [EB/OL]. 2023. <https://github.com/ggerganov/llama.cpp>.
- [15] DEEPSEEK-AI. DeepSeek-R1: incentivizing reasoning capability in LLMs via reinforcement learning[A/OL]. arXiv (2025). <https://arxiv.org/abs/2501.12948>.
- [16] AI Z. GLM-4 technical report[EB/OL]. 2024. <https://bigmodel.cn>.

致 谢

本论文的完成离不开许多人的帮助与支持。

首先，衷心感谢我的指导教师戈维峰副教授。在整个毕业设计过程中，戈老师从选题方向、研究方法到论文撰写规范都给予了悉心指导和宝贵建议。

感谢计算与智能创新学院的各位老师，在四年本科学习期间传授的专业知识和科研方法，为本论文的研究工作奠定了坚实的基础。

感谢开源社区的贡献者。本文的管线构建依赖于 `GradSLAM`、`Grounded-SAM`、`LLaVA`、`llama.cpp`、`Ollama` 等优秀的开源项目，`Code2Logic` 论文作者公开的 `GameQA` 数据集为本研究提供了重要的方法论参考和对比基线。`NVIDIA Isaac Sim` 团队提供了功能完备的仿真平台。

感谢我的同学和朋友们，在毕设过程中与我讨论技术问题、分享经验心得，在遇到困难时给予鼓励与支持。

最后，感谢我的家人多年来的关怀与付出，你们的理解与支持是我不断前行的动力。

学位论文独创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。论文中除特别标注的内容外，不包含任何其他个人或机构已经发表或撰写过的研究成果。对本研究做出重要贡献的个人和集体，均已在论文中作了明确的声明并表示了谢意。本声明的法律结果由本人承担。

作者签名：

任立德

日期：